Mathieu Bivert, CSSR, bivert@essi.fr

# PFE: Cahier des charges (DOW)

# Placement constraints for a better QoS in clouds

POLYTECH NICE-SOPHIA

**Entreprise** Université de Nice-Sophia Antipolis

**Lieu** Sophia-Antipolis, France

**Responsable** Fabien Hermenier, équipe OASIS, fabien.hermenier@unice.fr

**Résumé**

Dans le cadre de la répartition de machines virtuelles sur un ensemble de serveurs physiques, ce projet vise à formaliser puis implémenter des contraintes de placement, portant sur le type de systèmes de virtualisation.

**Abstract**

Within the framework of placing virtual machines on a set of physical servers, this project aims to formalize and to implement placement constraints, relative to the type of different virtualization systems.

# Contents

# 1 Description du projet

## 1.1 Contexte de travail

Le monde industriel étant de plus en plus informatisé, la qualité des réseaux s'améliorant, les sociétés informatiques tendent à louer des structures informatiques accessibles à distance.

Les hébergeurs de services informatiques étant spécialisées dans la maintenance de ces structures, elles sont plus performantes qu'une société spécialisée dans la construction d'automobiles par exemple. Cette dernière a alors tout interêt a déporter la charge de la conception et de la maintenance de ses systèmes d'informations à une entreprise de services. Cette dernière pourra offrir à ses clients des solutions personnalisées, et peu coûteuses par rapport à une gestion "manuelle".

À noter que cependant que toutes les entreprises n'ont pas forcément interêt à exporter leur centre de traitement de l'information : par exemple des structures reposant sur des données hautement confidentielles (recherche de pointe, armée, état, etc.).

Le terme de "cloud" correspond à un certain nombre de serveurs physiques et de logiciels, utilisés par une entreprise de services. Ces dernières se déclinent en plusieurs types selon le(s) service(s) qu'elles proposent:

**SaaS** Software As A Service, fournir un logiciel (eg. un client email : Gmail[1]);

**PaaS** Platform As A Service, fournir un ensemble de logiciels et services (eg. accès aux Google Apps[2]);

**IaaS** Infrastructure As A Service, fournir des ressources matérielles (eg. Amazon EC2[3]);

**DaaS** Data As A Service, fournir un accès à des données (eg. Dropbox[4]);

...

En particulier, un cloud *IAAS* fournit à l'utilisateur l'accès à un ensemble de systèmes d'exploitations. Ces derniers sont très souvent virtualisés, ce qui présente l'avantage de pouvoir faire tourner plusieurs OS sur un même serveur physique. La virtualisation repose sur un *hyperviseur*, c'est-à-dire un moniteur de machines virtuelles (VM), dont le but est réaliser l'isolation entre les différentes VMs et de les administrer. L'administration consiste à démarrer, arrêter, migrer, régler les ressources des VMs.

Par exemple, la figure 1 montre l'hyperviseur *Xen* [BDF+03] sous NetBSD en train de virtualiser un FreeBSD, deux NetBSDs et une Debian.

Une problématique pour les gestionnaires d'IAAS est donc de pouvoir placer correctement un ensemble donné de VMs sur un ensemble de serveurs physiques. Ce placement n'est pas libre : il est régit par un ensemble de contraintes qui doivent être satisfaites.

## 1.2 Motivations

La virtualisation présente plusieurs avantages:

- sur une application dite $n$-tiers, il est possible de placer chaque tiers sur une VM, et éventuellement d'en faire des duplications, ce qui améliore la robustesse de l'application. Par exemple, n cas de défaillance d'un serveur physique, il est stratégique d'avoir placé le réplicat d'un serveur de base de données sur un serveur différent de l'original;
- l'admninistration et la gestion des machines est simplifiée : il y a moins de hardware, donc moins de maintenance physique; la possibilité de pouvoir cloner/charger/décharger à la volée des VMs permet d'améliorer la QoS facilement. Notamment, dans le cas où l'administrateur doit effectuer une opération de maintenance sur un serveur physique, il va devoir migrer [CFH+05] les VMs sur un autre serveur;
- chaque application peut être répartie sur une VM différente. Ainsi, si une application est compromise, elle a moins de chances de pouvoir compromettre d'autres applications que si elles étaient toutes lancées sous un même OS;

[1] `https://gmail.com`
[2] `https://www.google.com/enterprise/apps/business/`
[3] `https://aws.amazon.com/ec2/`
[4] `https://www.dropbox.com/`

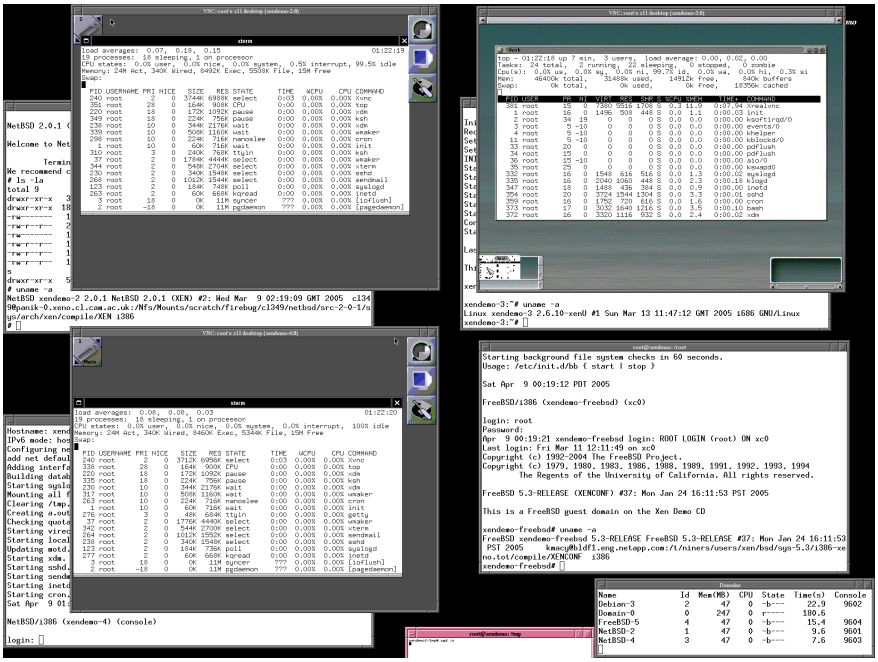

Figure 1: Virtualisation avec Xen; trois clients VNC [5]sont lancés pour accéder aux VMs

- utilisation plus performante du matériel, lorsqu'un ordinateur puissant peu être utilisé au maximum de ses performances en faisant tourner plusieurs systèmes d'exploitations. Cependant, utiliser un serveur à 99% de ses capacités n'est pas judicieux, puisque celui-ci sera alors incapable d'assurer une augmentation de charge. Il est donc impératif d'éviter une saturation;
- ...

La question de la répartition des machines virtuelles sur les machines physiques se pose alors pour des raisons diverses et variées:

**maintenance** un serveur physique peut tomber en panne, ou nécessiter une réparation, auquel cas les programmes tournant dessus doivent être migré ailleurs, afin de garantir au client une certaine qualité de service (QoS);

**sécurité** il peut s'avérer risquer pour un programme d'un client traitant des données sensibles (eg. données bancaires) de se retrouver au même endroit qu'un programme d'un autre client;

**évolution des besoins** où au cours d'un certain intervalle de temps, les besoins en puissance de calcul d'une entreprise peuvent augmenter (suite à une plus grande popularité par exemple), ou encore, augmentation brusque et irrégulière de la charge à des heures de pointes;

**économie d'énergie** où il peut être avantageux de réduire le nombre de serveurs physiques allumés, pour maximiser le rendement des autres machines physiques du cloud;

**QoS** où, à l'inverse de l'économie d'énergie, il est bon de garder des ressources supplémentaires disponibles immédiatement, de façon à ne pas perdre de temps (et donc en QoS) à redémarrer un autre serveur;

**licence** les entreprises fournissant les systèmes de virtualisation proposent des licences selon différents critères (eg. nombre de machines virtuelles lancées, utilisation de ressources (CPU, RAM, etc.));

**plateforme** plusieurs plateformes de virtualisations sont disponibles (eg. Xen, VMWare, Citrix); une autre contrainte sur la répartition des machines virtuelles se pose alors, un serveur physique ne faisant tourner qu'un seul type de plateforme;

[5]`http://www.hep.phy.cam.ac.uk/vncdocs/index.html`

...

Enfin, on notera que ces besoins fluctuent au cours du temps; les systèmes de placement doivent donc être flexibles, au moins à deux niveaux. D'abords, ils doivent être *configurable* afin de prendre en compte les spécificités et les propriétés, éventuellement variables des applications et du datacenter. Une deuxième propriété d'*extensibilité* est nécessaire, ce afin d'être capable de supporter de nouvelles fonctionnalités au fur et à mesure de l'évolution des besoins.

## 1.3 Défis

Afin de compléter le manque de fonctionalités, l'ajout de contraintes à la volée est requise. Malgré un contexte fortement combinatoire (eg. le placement d'une VM influençant le placement d'autres VMs, la viabilité des contraintes), l'approche se doit d'être suffisamment flexible.

La solution proposée par l'algorithme BtrPlace [6] va dans ce sens : il utilise la programmation par contrainte pour trouver une solution viable au placement, en un temps assez "court" pour gérer un datacenter conséquent (5000 serveurs, 30000 VMs en 3 minutes) de nouvelles contraintes peuvent être ajoutées sous formes de plugins Java en une trentaine de lignes de code, etc.

## 1.4 Objectifs

Actuellement, les trois/quatres derniers points cités ne sont pas forcément formalisés/implémentés complètement. Le projet consiste donc à choisir l'un de ces domaines et à l'ammener vers une forme satisfaisante.

Le dernier point est celui sur lequel se porte ce projet. Le travail sera d'autant plus original que les questions d'économies d'énérgies sont actuellement très prisées par les chercheurs au détriment des autres.

Au sein d'une infrastructure, plusieurs types d'hyperviseurs/de VMs doivent être supportés. Afin de satisfaire le critère de flexibilité, on peut avoir besoin de changer le système de supervision des VMs d'un serveurs dynamiquement. Par exemple, on peut désirer vouloir garantir une certaines proportions d'une plateforme donnée, un nombre maximum de plateformes d'un certain type, etc.

Dans l'état actuel, BtrPlace est incomplet : il ne permet pas de gérer le type des VMs/plateformes ni les étapes de reconfiguration. Dans ce sujet, on se propose donc dans un premier temps, d'étendre le modèle actuel pour supporter le typage des infrastructures. C'est-à-dire, fournir une implémentation de base permettant d'associer un type à une machine virtuelle, et un ensemble de types possibles pour un serveur. En effet, ces derniers peuvent ne pas supporter n'importe quel hyperviseur.

Dans un second temps, on modélise et implémente un ensemble de contraintes pour contrôler les plateformes selon leur type. Par exemple, on peut limiter le nombre de plateformes d'un type donné, interdire un changement de type sur un serveur, etc.

## 1.5 Scénarios

On reprend l'exemple précèdent sur la figure 2 avec des informations plus proches de ce qu'il se passe en réalité.

Sur le diagramme 2(a), on souhait mettre le serveur physique $N_2$ hors-ligne pour des questions de maintenance. On utilise pour cela la contrainte *offline($N_i$);*[7].

Comme aucun serveur VMWare n'est disponible, il est nécessaire de supprimer un serveur Xen, capable d'accueillir $VM_3$, par exemple $N_1$. Les machines virtuelles situées sur ce dernier, $VM_1$ et $VM_2$, doivent dans un premier temps être migrées sur un autre serveur.

Puis, $N_1$ doit s'éteindre et redémarrer en changeant son système de virtualisation. Enfin, la $VM_3$ est déplacée sur $N_1$, et $N_2$ peut être éteint, pour arriver dans l'état décrit par le diagramme 2(b).

[6] `http://btrp.inria.fr/sandbox/about.html`; il est mis en place dans Entropy [FH09], un manager de clusters

[7] `http://www-sop.inria.fr/members/Fabien.Hermenier/btrpcc/offline.html`

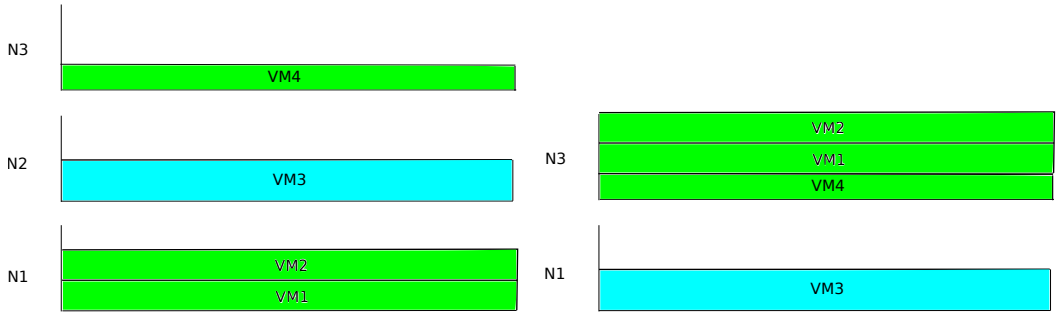


(a) Avant la reconfiguration (b) Après la reconfiguration

Figure 2: Exemple de changement de système de virtualisation. En vert des VMs Xen, en cyan une VM VMWare

### 1.6 Critère de succès

L'extension apportée à BtrPlace devra supporter correctement les problèmes de dépendances en le placement des VMs, le typage des serveurs et l'éventuel changement dynamique de type de ceux-ci. Enfin, les contraintes doivent être censées, bien définies et répondre à des besoins concrets.

## 2 État de l'art

### 2.1 Description générale

Historiquement, les gestionnaires de placement se sont concentrés sur le placement des VMs selon leurs besoins en ressources (CPU, RAM, BP, etc.), tout en cherchant à réduire la consommation énergétique

Traditionnellement, ces approches reposent sur des algorithmes ad'hoc rapides pour répartir les VMs. D'autres algorithmes plus flexible ont vu le jours suite aux demandes des clients, par exemple portant sur la fiabilité des applications.

Une approche prise par [GJ10] consiste à utiliser une fonction d'utilité pour les applications à haute disponibilité. Leur solution est prévue pour fonctionner dans le cas d'une défaillance d'un serveur physique, mais n'est nullement adaptée pour répondre à des changements de charge. De plus, l'ajout de nouveaux paramètres tels que la gestion des types des serveurs nécessite de revoir l'algorithme de reconfiguration. Enfin, les tests sont limités à un datacenter d'une douzaine de serveurs.

VMWare DRS suit une approche similaire à celle de BtrPlace en donnant à l'administrateur un accès à quelques contraintes (plus ou moins équivalentes à *ban*, *fence*, *gather* et *spread*). Cependant, leur version de *spread* ne garantit pas que lors du déplacement d'une VM, l'ancienne et la nouvelle version de celle-ci ne vont pas se superposer. DRS n'est pas prévu pour être étendu, et il lui manque 5 contraintes par rapport à BtrPlace. Enfin, l'administration est limitée à des clusters de 32 serveurs.

Entropy est à l'origine de BtrPlace. La programmation par contraintes est utilisée pour placer les VMs sur un nombre minimum de serveur. L'ordonnancement des actions nécessaires à la migration étant calculé avec une heuristique ad'hoc, il est impossible d'ajouter des contraintes telles que *spread*, qui affectent l'ordonnancement. Finalement, toutes les VMs en marche sont prises en compte lors de la résolution d'un mauvais placement, ce qui limite le nombre de serveurs gérés à quelques centaines.

Récemment, de nouvelles approches plus flexibles ont vu le jour; elles permettent d'intégrer des contraintes de placement à la demande. Bin et al. utilise aussi la programmation par contraintes pour fournir un gestionnaire de placement modulaire. Ils permettent une haute-disponibilité en guarantissant qu'à chaque instant, un certains nombre de serveurs sera disponible pour satisfaire la consommation de ressources des VMs et les contraintes de déplacement. Lorsqu'un serveur a de fortes chances de tomber en panne, les VMs sont migrés sur un autre capable de les satisfaire. Le modèle proposé ne supporte pas les contraintes portant sur la gestion de l'état des serveurs, l'ordonnancement des actions ou encore sur la façon dont les VMs sont migrées. Enfin, l'extensibilité n'a été vérifiée que pour 32 serveurs physiques et 128 VMs au maximum.

Quelques aspects théoriques de BtrPlace ont été étudiés au préalable, avec un premier prototype

| Id | Titre du livrable | Lot(s) | Nature | Date |
|---|---|---|---|---|
| $D_0$ | Cahier des charges | 1 | Document | $S_4$ |
| $D_1$ | Gestion du typage et du déploiement | 1 | Document | ? |
| $D_2$ | Ensemble de contraintes | 1 | Document et Logiciel | ? |
| $D_3$ | Rapport de management | 1 | Document | $S_{20}$ |
| $D_4$ | Diaporama de présentation finale | 1 | Document | $S_{20}$ |

| Id | Jalon de fin de phase | Lot(s) | Date | Vérification |
|---|---|---|---|---|
| $J_0$ | planification | 1 | $S_4$ | $D_0$ |
| $J_1$ | formalisation | 1 | $S_n$ | $D_1$ partiel |
| $J_2$ | implémentation | 1 | $S_{n+k}$ | $D_2$, $D_1$ partiel |
| $J_3$ | projet | 1 | $S_{20}$ | $D_1$, $D_2$, $D_3$ et $D_4$ |

prenant en compte les ressources allouées aux VMs, leur placement et l'étape de migration. [FH12] étends ce travail en montrant que BtrPlace est capable de gérer des datacenters de plusieurs centaines de serveurs. BtrPlace est donc à l'heure actuelle le gestionnaire le plus efficace en ce qui concerne le placement de VMs, tout en rendant possible de contrôler l'état des serveurs et les sur-allocations de ressources. L'addition d'une dizaine de nouvelles contraintes répondant à ces besoins démontre une extensibilité correcte. L'utilisation d'une heuristique basée sur une optimisation de filtre rends BtrPlace jusqu'à 20 fois plus rapide sur la gestion de datacenters composés de 2500 serveurs.

La scalabilité de BtrPlace est testée sur Grid'5000[8]. Celle-ci est une plateforme designée pour aider la recherche expérimentale en informatique, et ce dans plusieurs domaines, comme le calcul parallèle, distribué, le réseau, etc. Grid'5000 repose sur Kadeploy[9], un ensemble d'outils permettant de manager un ensemble de nœuds. Une autre plateforme, Emulab[10] joue un rôle similaire, et permet par exemple de créer des topologies réseaux virtuelles à la volée.

Grid'5000 comme Kadeploy incluent chacune un algorithme de placement permettant de redéployer une VM au besoin. Par contre, aucun d'eux ne supporte des contraintes ou la gestion de licence, ou encore la préparation de plateforme à l'avance.

Donc pour résumer, aucun système existant hormis BtrPlace ne scale correctement, et aucun ne supporte le typage des VMs/nœuds, ni même les moyens de l'exprimer telle quelle avec leur modèle.

# 3 Méthodologie et planification

## 3.1 Stratégie générale

## 3.2 Découpage en lots

bis repetita: trouver un bon formalisme; définir et implémenter

## 3.3 Plannification

gantt

## 3.4 Livrables associés au projet

## 3.5 Jalons

# 4 Description de la mise en œuvre du projet

## 4.1 Interdépendance des lots et tâches

bis repetita: trouver un bon formalisme; définir et implémenter

[8] `https://www.grid5000.fr`
[9] `http://kadeploy.imag.fr/`
[10] `http://www.emulab.net/`

### 4.2 Description des lots

bis repetita: trouver un bon formalisme; définir et implémenter

### 4.3 Résumé de l'effort

### 4.4 Gestion du risque

## 5 Participants

### 5.1 Mathieu Bivert - CSSR

Étudiant à Polytech'Nice Sophia, spécialisé en Cryptographie, Systèmes Sécurité et Réseaux.

### 5.2 Fabien Hermenier - OASIS/INRIA

**Fabien Hermenier** a recu un doctorat en 2009 à l'université de Nantes. Depuis 2011, il enseigne en tant que Maître de conférence à l'université de Nice Sophia-Antipolis. Son travail de recherche s'articule autour des plateformes d'hébergement, de la virtualisation, du calcul autonome et de la gestion des ressources. Depuis 2006, il travaille sur des algorithmes de placement de machines virtuelles pour faire face à l'augmentation des SLA dans les plateformes d'hébergements.

# Références


[BDF+03] P. Barham, B. Dragovic, K. Fraser, S. Hand, T. Harris, A. Ho, R. Neugebauer, I. Pratt, and A. Warfield. Xen and the art of virtualization. In *ACM SIGOPS Operating Systems Review*, volume 37, pages 164–177. ACM, 2003.

[CFH+05] C. Clark, K. Fraser, S. Hand, J.G. Hansen, E. Jul, C. Limpach, I. Pratt, and A. Warfield. Live migration of virtual machines. In *Proceedings of the 2nd conference on Symposium on Networked Systems Design & Implementation-Volume 2*, pages 273–286. USENIX Association, 2005.

[FH09] Jean-Marc Menaud Gilles Muller Julia Lawall Fabien Hermenier, Xavier Lorca. Entropy : a consolidation manager for clusters. 2009.

[FH12] Gilles Muller Fabien Hermenier, Julia Lawall. Btrplace : A flexible consolidation manager for highly available applications. 2012.

[GJ10] M.A. Hiltunen R.D. Schlichting C. Pu G. Jung, K.R. Joshi. Performance and avaibility aware regeneration for cloud based multitier applications. 2010.